

Contenido

FICEM Watch - Propuesta Técnica de Implementación	1
Resumen Ejecutivo	1
Arquitectura de Dos Capas	2
Casos de Uso	3
Por qué los RAG Tradicionales Fallan	4
Análisis ROI: GraphRAG vs RAG Avanzado	6
Plan de Implementación	6
FASE 1: Prototipo Diferenciador (2 Semanas)	6
FASE 2: Implementación Profesional (2-3 Meses)	10
Riesgos y Mitigaciones	12
Diferenciadores de FICEM Watch	13
Recursos Disponibles	14
Próximos Pasos Inmediatos	14
Anexo: Referencias Técnicas	14

FICEM Watch - Propuesta Técnica de Implementación

Asistente Ejecutivo de Posicionamiento Estratégico

Fecha: Enero 2026 **Versión:** 1.1 **Preparado para:** FICEM (Federación Interamericana del Cemento)

Resumen Ejecutivo

FICEM Watch es un sistema de **posicionamiento estratégico** diseñado para directivos de FICEM. No es simplemente un buscador de documentos ni un chatbot genérico: es una herramienta que combina el conocimiento institucional de FICEM con su estrategia comunicacional para generar respuestas alineadas con la voz de la organización.

FICEM Watch NO es un buscador de documentos; es una herramienta de comunicación política y técnica.

Problema que Resuelve

Los directivos de FICEM enfrentan diariamente: - Solicitudes de posicionamiento urgente ante noticias del sector - Necesidad de consultar historial de posiciones anteriores - Requerimientos de datos duros para interpelaciones de gobiernos/medios - Preparación de briefings ejecutivos en tiempos reducidos

Solución Propuesta

Un asistente inteligente que en minutos proporciona: - Respuestas **informadas** (basadas en ~94 documentos institucionales) - Respuestas **alineadas** (con la estrate-

gía comunicacional de FICEM) - Con **citas verificables** (nunca inventa información) - Con **alertas** sobre temas sensibles que requieren validación humana

Arquitectura de Dos Capas

El diferenciador clave de FICEM Watch es su arquitectura de dos capas que garantiza respuestas no solo correctas, sino estratégicamente alineadas.

Capa 1: Conocimiento (Qué sabe FICEM)

Componente	Descripción
Base documental	~94 documentos en 10 categorías
Tecnología	RAG (Retrieval-Augmented Generation)
Almacenamiento	Base de datos vectorial (Qdrant)
Búsqueda	Híbrida (semántica + palabras clave)

Categorías de documentos disponibles: - Coprocesamiento - Emisiones CO2/GEI - Institucional FICEM - Reportes de Sostenibilidad - Buenas Prácticas - Actas de Congresos - Documentos internos - Referencias GCCA, BID, CAF

Capa 2: Estrategia Comunicacional (Cómo comunica FICEM)

El sistema no solo busca información; **filtra y formula respuestas** según:

Elemento	Función
Tono institucional	Formal, técnico, propositivo (no reactivo/defensivo)
Mensajes clave	Pilares comunicacionales que FICEM siempre refuerza
Públicos objetivo	Adapta mensaje según audiencia (gobierno, industria, medios)
Temas sensibles	Identifica temas que requieren validación humana
Posicionamiento diferencial	Lo que distingue a FICEM de otras voces del sector


Flujo de Generación de Respuesta

Pregunta del usuario

|
v

[Capa 1: Conocimiento]

Busca información relevante en base de datos



Casos de Uso

1. Respuesta Rápida a Noticias

Escenario: “Salió una noticia sobre impuestos al carbono en Colombia, ¿qué debemos decir?”

Capa	Aporte
Conocimiento	Posición histórica de FICEM + contexto regional + datos relevantes
Estrategia	Formulación con tono institucional + alineación con mensajes clave

Output: Respuesta sugerida lista para usar, con citas verificables

2. Consulta de Historial

Escenario: “¿Qué hemos dicho sobre factores clínter en los últimos 3 años?”

Capa	Aporte
Conocimiento	Línea de tiempo de posiciones + documentos clave + evolución
Estrategia	Identificación de cambios de postura + coherencia con lineamientos actuales

Output: Resumen ejecutivo de evolución del discurso + alertas si hay inconsistencias

3. Datos Duros para Interpelaciones

Escenario: “Gobierno pregunta cuántas empresas cumplen con X norma”

Capa	Aporte
Conocimiento	Estadísticas precisas + fuentes verificables + comparación regional
Estrategia	Contexto narrativo (enfaticar logros, reconocer desafíos)

Output: Datos con narrativa alineada a posicionamiento FICEM

4. Reporte Ejecutivo Urgente

Escenario: “Necesito briefing completo sobre co-procesamiento para reunión en 1 hora”

Capa	Aporte
Conocimiento	Datos técnicos + posiciones históricas + referencias documentales
Estrategia	Estructura y tono según audiencia de la reunión

Output: Reporte ejecutivo de 2 páginas con voz institucional FICEM

5. Tema Sensible

Escenario: “¿Qué responder sobre el caso de contaminación en planta X?”

Capa	Aporte
Conocimiento	Información disponible sobre el caso + contexto
Estrategia	ALERTA: Tema sensible - requiere validación humana

Output: Borrador de respuesta + flag de revisión obligatoria

Por qué los RAG Tradicionales Fallan

Investigación de Mercado

El 72-80% de los proyectos RAG empresariales fallan en producción. La investigación académica (Barnett et al., 2024/2025) identifica 7 puntos de falla:

#	Punto de Falla	Descripción
1	Contenido Faltante	La respuesta no está en los documentos, pero el sistema inventa
2	Fallo en Ranking	El fragmento correcto existe pero no llega al Top K
3	Fuera de Contexto	Se recuperó pero no entró al prompt por límites
4	No Extraído	Está en el prompt pero el LLM no lo "ve" entre el ruido
5	Formato Incorrecto	El modelo no sigue las reglas de salida
6	Especificidad Incorrecta	Respuesta demasiado general o técnica
7	Incompleto	Solo recupera parte de la respuesta distribuida

El Fenómeno "Lost in the Middle"

Los modelos de lenguaje leen bien el inicio y final del contexto, pero **ignoran información en el medio**. Si la respuesta está en el fragmento 5 de 10, hay alta probabilidad de fallo.

El Problema de los PDFs

Los PDFs son el **peor formato para RAG** porque "pintan" texto en coordenadas en lugar de mantener una estructura lógica. Si se corta una tabla por la mitad, se pierde la relación entre columnas.

Nota Crítica: El fallo principal de los prototipos corporativos suele ser la **extracción**. Si el texto que entra a la base de datos es basura (tablas rotas, encabezados mezclados), el mejor LLM del mundo fallará. **Invertir el 60% del tiempo en el Parsing.**

Solución: RAG Avanzado

FICEM Watch implementa técnicas de RAG Avanzado que mitigan estos fallos:

Técnica	Problema que Resuelve
Layout-aware Parsing (Docling)	Extracción correcta de tablas y estructura
Indexación en Markdown	Preserva relación estructural de tablas
Chunking semántico	Fragmentos coherentes por tema, no por caracteres
Búsqueda híbrida (Vectores + BM25)	Encuentra tanto conceptos como datos exactos

Técnica	Problema que Resuelve
Re-ranking (Cohere)	Elimina ruido, prioriza relevancia real
Small-to-Big Retrieval	Búsqueda precisa + contexto expandido
Filtros de metadatos	Si pregunta por “2024”, filtra antes de buscar

Análisis ROI: GraphRAG vs RAG Avanzado

Característica	Advanced RAG (Vectores + Re-ranker + Metadata)	GraphRAG (Nodos y Relaciones)
Tiempo de implementación	3-5 días	3-6 semanas
Complejidad	Media	Muy Alta
Precisión en datos técnicos	Muy Alta (con Re-ranker)	Superior en relaciones complejas
Costo de inferencia	Bajo / Medio	Muy Alto

Decisión para prototipo de 2 semanas: No implementar GraphRAG desde cero (quedaría atrapado en limpieza de datos). El mejor ROI es **Hybrid RAG + Re-ranking**.

Plan de Implementación

Visión General

Fase	Duración	Objetivo
Fase 1: Prototipo	2 semanas	Demostrar valor y diferenciación
Fase 2: Producción	2-3 meses	Sistema robusto y evaluado

FASE 1: Prototipo Diferenciador (2 Semanas)

Objetivo

Construir un prototipo funcional que demuestre: 1. Capacidad de respuesta basada en documentos FICEM 2. Diferencia tangible respecto a RAG básicos que no funcionan 3. Potencial de la arquitectura de dos capas

El enfoque **NO** es “más documentos”, sino “**extracción de altísima calidad + inteligencia en la recuperación**”.

Cronograma Detallado

Días	Actividad Crítica	Entregable
1-3	Parsing de Oro: Procesar 94 docs con Docling	Carpeta de archivos .md limpios
4-6	Indexación Híbrida: BM25 + Vectores con metadatos	Base de datos Qdrant funcional
7-9	Capa 2 (Estrategia): System Prompt y Re-ranking	Pipeline funcional con tono FICEM
10-12	Evaluación Sintética: Correr RAGAS sobre 40-50 preguntas	Reporte de precisión inicial
13-14	Demo UI: Interfaz que muestre Fuente y Pilar Estratégico	Prototipo funcional para directivos

Stack Tecnológico Fase 1

Componente	Tecnología	Justificación
Parsing	Docling (IBM)	Superior para tablas técnicas, convierte a Markdown preservando estructura
Alternativas parsing	Unstructured.io, Marker	Unstructured usa visión para bounding boxes; Marker es rápido para fórmulas
Vector DB	Qdrant	Mejor soporte para búsqueda híbrida, fácil de levantar en Docker
Búsqueda	Híbrida (Vectores + BM25)	Encuentra conceptos Y datos exactos
Re-ranker	Cohere Rerank v3 Multilingual	Estándar de oro, drásticamente superior en español técnico
Alternativas re-ranker	Jina Reranker v2, BGE-M3, Mixedbread.ai	Jina para chunks largos; BGE-M3 si se requiere open-source
Chunking	SemanticChunker (LangChain)	Detecta rupturas de cohesión, fragmentos coherentes por tema
Embeddings	paraphrase-multilingual-MiniLM-L12-v2	Buen rendimiento en español técnico
LLM	Claude 3.5 Sonnet	Redacción matizada, ideal para comunicaciones políticas
Orquestador	LangChain o LlamaIndex	Ambos soportan Hybrid Search out-of-the-box

Componente	Tecnología	Justificación
UI	Streamlit	Desarrollo rápido, familiar para directivos

Detalle Técnico de Cada Etapa

Días 1-3: Parsing de Documentos (60% del éxito) **Principio crítico:** Si la extracción de texto es deficiente, el mejor LLM fallará.

Herramientas de Layout-aware Parsing:

Herramienta	Fortaleza
Docling (IBM)	Mejor para convertir PDFs complejos a Markdown, preserva tablas perfectamente
Unstructured.io	Usa modelos de visión para detectar bounding boxes (títulos, tablas, imágenes)
Marker	Muy rápido, alta fidelidad en fórmulas y tablas

Proceso: 1. Procesar 94 PDFs con Docling 2. Convertir a Markdown (preserva tablas como texto estructurado) 3. Validar calidad con muestra aleatoria (5%) usando LLM "auditor" 4. Verificar especialmente: números, porcentajes, datos de emisiones

Estrategia clave: No indexar texto plano. **Indexar Markdown.** Las tablas en Markdown mantienen la relación estructural y son fácilmente "entendibles" por embeddings y LLM.

Manejo de tablas complejas: - Docling normaliza celdas fusionadas (repite valores o usa estructura plana) - El título de la tabla se adjunta a cada chunk - Formato Markdown permite al LLM razonar sobre filas/columnas

Días 4-6: Indexación Híbrida Small-to-Big Retrieval: - Guardar chunks pequeños (oraciones) con su embedding - En metadatos: ID del párrafo padre - **Búsqueda:** encontrar oración precisa (mayor precisión) - **Recuperación:** traer párrafo completo para contexto al LLM

Metadatos por documento:

```
{
  "categoria": "coprocesamiento",
  "subcategoria": "normativa",
  "fecha": "2024-03-15",
  "year": 2024,
  "fuente": "Reporte_Sostenibilidad_2024.pdf",
  "pagina": 45,
```



```
"nivel_acceso": "interno"
}
```

Filtros de metadatos: Si el usuario pregunta por “Manuales 2024”, filtrar por metadato year: 2024 **antes** de buscar semánticamente.

Días 7-9: Capa 2 (Estrategia) System Prompt con Chain of Thought (CoT):

Instrucciones:

1. Primero, extrae los hechos del contexto recuperado
2. Segundo, identifica cuál de los 3 pilares estratégicos de FICEM aplica
3. Tercero, redacta la respuesta usando el tono institucional

Tono FICEM: Formal, técnico, propositivo (nunca defensivo o reactivo)

Siempre incluir citas verificables con documento y página

Si no hay información, decir "No tengo información oficial sobre esto"

Detección de temas sensibles (Clasificación Previa): - Paso intermedio con LLM rápido (GPT-4o mini) - Pregunta: “¿Es este un tema de crisis o interpelación?” - Si es sensible: agregar alerta visual: ⚠ “Esta respuesta requiere validación del departamento de comunicación”

Re-ranking con Cohere: - Recuperar 20-50 fragmentos usando vectores - Pasarlos por Cohere Rerank v3 Multilingual - Reordenar basándose en relevancia real respecto a la pregunta - Esto sube la precisión del 60% al 90% inmediatamente

Días 10-12: Evaluación RAGAS Generación de Dataset Sintético (LLM-as-a-Judge):

No se necesita historial humano. El flujo es: 1. Tomar documentos reales 2. LLM potente (GPT-4o o Claude 3.5) analiza chunks y genera: - Una pregunta - Una respuesta ideal - El contexto de donde la sacó 3. RAGAS puede generar preguntas “difíciles” (razonamiento, multihop, con trampas)

Tamaño del dataset: 40-50 pares pregunta/respuesta (mínimo para ser estadísticamente relevante)

Métricas RAGAS a monitorear:

Métrica	Qué mide
Faithfulness	¿La respuesta se inventó algo o está 100% en los documentos?
Answer Relevance	¿Responde realmente a lo que el usuario preguntó?
Context Precision	¿Los fragmentos recuperados eran realmente útiles?

Automatización: Integrar RAGAS para que corra ante cambios de parámetros (prompt, tamaño de chunk) y detecte regresiones.

Días 13-14: Demo UI Interfaz Streamlit: - Chat conversacional (familiar tipo Chat-GPT) - Mostrar fuentes citadas con links a documentos - Indicar pilar estratégico aplicado - Alertas visuales para temas sensibles - Export a PDF/Word

Entregables Fase 1

1. **Prototipo funcional** demostrable a directivos
 2. **Base de conocimiento** con 94 documentos indexados en Markdown
 3. **Reporte de evaluación** con métricas RAGAS (Faithfulness, Answer Relevance, Context Precision)
 4. **Documentación técnica** del pipeline implementado
-

FASE 2: Implementación Profesional (2-3 Meses)

Objetivo

Sistema robusto, evaluado y listo para uso en producción con las dos capas completamente funcionales.

Mes 1: Consolidación y Mejoras

Semana	Actividad
1-2	Refinamiento del parsing basado en feedback
2-3	Optimización de chunking y re-ranking
3-4	Integración de lineamientos comunicacionales formales

Lineamientos Comunicacionales: - Levantamiento formal con área de comunicaciones FICEM - Documento estructurado: tono, mensajes clave, públicos, temas sensibles - Validación por directivos antes de implementar

Formato del documento de lineamientos:

LINEAMIENTOS COMUNICACIONALES FICEM

=====

1. TONO INSTITUCIONAL
 - Características: [lista]
 - Evitar: [lista]
2. MENSAJES CLAVE
 - Pilar 1: [descripción]
 - Pilar 2: [descripción]
 - Pilar 3: [descripción]
3. PÚBLICOS Y ADAPTACIÓN

- Gobierno: [cómo adaptar]
 - Industria: [cómo adaptar]
 - Medios: [cómo adaptar]
 - Sociedad civil: [cómo adaptar]
4. TEMAS SENSIBLES (requieren validación humana)
- [tema 1]: por qué es sensible
 - [tema 2]: por qué es sensible
5. EJEMPLOS DE REFERENCIA
- Buen ejemplo: [link/cita]
 - Contraejemplo: [qué evitar]

Mes 2: Escalamiento y Robustez

Semana	Actividad
1-2	GraphRAG para relaciones temporales entre posiciones
2-3	Multi-model LLM (Claude primary + GPT fallback)
3-4	Role-based access control (gobernanza de datos)

GraphRAG: - Extracción de entidades y relaciones de documentos - Grafo de conocimiento para navegación semántica (Neo4j o FalkorDB) - Permite preguntas como “¿Cómo evolucionó nuestra posición sobre X?” - Entiende relaciones: si preguntas “¿Cómo afecta el cambio de política Y a los clientes de Europa?”, navega por la relación legal entre esos nodos

Gobernanza: - Metadatos de permisos en cada documento - Filtrado por rol de usuario antes de generar respuesta - Niveles: público, interno, confidencial

Mes 3: Producción y Monitoreo

Semana	Actividad
1-2	Pipeline de actualización de documentos
2-3	Dashboard de monitoreo y métricas
3-4	Capacitación usuarios + go-live

Pipeline de ingesta: - Proceso definido para nuevos documentos - Validación antes de indexar - Versionamiento de base de conocimiento

Preguntas críticas a definir: 1. ¿Quién sube documentos nuevos? 2. ¿Qué formato estándar usarán? (PDF, Word, Excel) 3. ¿Cómo se etiquetan? (metadatos: tema, fecha, confidencialidad) 4. ¿Cada cuánto se actualizan? 5. ¿Quién valida que la información es correcta antes de ingestar?

Stack Tecnológico Fase 2

Componente	Fase 1	Fase 2 (Mejora)
Vector DB	Qdrant local	Qdrant Cloud (escalable)
Grafos	-	Neo4j / FalkorDB (GraphRAG)
LLM	Claude 3.5	Claude + GPT fallback
Monitoreo	Manual	Dashboard automatizado
Auth	Básica	SSO + RBAC
Evaluación	RAGAS manual	RAGAS en CI/CD

Entregables Fase 2

1. **Sistema en producción** con SLA definido
2. **Lineamientos comunicacionales** formalizados e implementados
3. **GraphRAG** para consultas de evolución temporal
4. **Gobernanza de datos** con control de acceso por roles
5. **Pipeline de actualización** documentado
6. **Dashboard de métricas** operacionales
7. **Manual de usuario** y capacitación completada

Riesgos y Mitigaciones

Alto Impacto

Riesgo	Mitigación
Alucinaciones del LLM	Citas obligatorias + validación humana para uso público + Faithfulness score
Datos desactualizados	Timestamp visible + alerta de antigüedad + source freshness score
Desalineación comunicacional	Lineamientos formalizados + feedback loop + revisión periódica
Acceso no autorizado	RBAC + logs de auditoría
Extracción deficiente (PDFs)	Invertir 60% del tiempo en parsing + validación con LLM auditor

Medio Impacto

Riesgo	Mitigación
Dependencia de LLM externo	Multi-model con fallback
Costo operativo	Cache de respuestas + tier controlado
Deriva de contexto	Priorizar fechas + señalar cambios de postura explícitamente

Riesgo	Mitigación
Cultural capture (sesgo hacia organizaciones dominantes como GCCA)	Ponderación explícita de fuentes FICEM vs externas + audit trail
Information overload	Outputs en capas (resumen ejecutivo → detalles bajo demanda)

Diferenciadores de FICEM Watch

Vs. Chatbots Genéricos (ChatGPT, etc.)

Aspecto	Chatbot Genérico	FICEM Watch
Conocimiento	General, puede inventar	Específico FICEM, con citas
Tono	Genérico	Institucional FICEM
Fuentes	Desconocidas	Documentos verificables
Sensibilidad	No detecta	Alerta temas críticos

Vs. RAG Básicos

Aspecto	RAG Básico	FICEM Watch
Parsing	PyPDF (pierde tablas)	Docling (preserva estructura en Markdown)
Chunking	Por caracteres	Semántico por tema
Búsqueda	Solo vectorial	Híbrida + Re-ranking
Estrategia	Ninguna	Capa 2 comunicacional
Evaluación	Anecdótica	RAGAS automatizado
Precisión	~60%	~90% (con re-ranking)

Vs. Mercado Actual

Característica	Mercado	FICEM Watch
Enfoque	Corporaciones individuales	Asociaciones industriales
Región	USA/Europa	Latinoamérica
Idioma	Inglés	Español (ES/EN/PT)
Sector	Genérico	Cemento/Concreto

Recursos Disponibles

Documentos (94 archivos)

Categoría	Cantidad
Coprocesamiento	12
Emisiones CO2/GEI	15
Institucional FICEM	8
Reportes Sostenibilidad	30
Buenas Prácticas	41
Congresos	5
Referencias externas	14+

Ubicación: Indexados y disponibles para procesamiento

Infraestructura

- Ambiente de desarrollo configurado
 - APIs de LLM disponibles (Claude, OpenAI)
 - Acceso a Cohere para Re-ranking
-

Próximos Pasos Inmediatos

Para iniciar Fase 1

1. **Aprobación** de este plan de implementación
2. **Acceso** a documentos FICEM para parsing
3. **Definición** de lineamientos comunicacionales preliminares
4. **Identificación** de 2-3 directivos para pruebas piloto

Para preparar Fase 2

1. **Sesiones** con área de comunicaciones para levantamiento de lineamientos
 2. **Definición** de roles y permisos de acceso
 3. **Pipeline** de actualización de documentos
-

Anexo: Referencias Técnicas

Papers Fundamentales

- Barnett et al. (2024/2025): "Seven Failure Points When Engineering a Retrieval Augmented Generation System"
- Liu et al.: "Lost in the Middle" - comportamiento de LLMs con contexto largo
- "REPLUG: Retrieval-Augmented Black-Box Language Models"

Herramientas Seleccionadas

Herramienta	Uso	Documentación
Docling (IBM)	Parsing PDF→Markdown	github.com/DS4SD/docling
Unstructured.io	Parsing alternativo con visión	unstructured.io
Marker	Parsing rápido	github.com/VikParuchuri/marker
Qdrant	Vector DB híbrida	qdrant.tech
Cohere Rerank v3	Re-ranking multilingüe	cohere.com/rerank
Jina Reranker v2	Re-ranking para chunks largos	jina.ai
BGE-M3	Re-ranking open-source	huggingface.co/BAAI
LangChain	Orquestación	langchain.com
LlamaIndex	Orquestación alternativa	llamaindex.ai
RAGAS	Evaluación RAG	ragas.io
DeepEval	Evaluación alternativa	deepeval.com
Streamlit	UI rápida	streamlit.io
Neo4j	GraphRAG (Fase 2)	neo4j.com
FalkorDB	GraphRAG alternativo	falkordb.com

Frameworks Evaluados

Framework	Recomendación
LangChain	Estándar industria, usar para prototipo
LlamaIndex	Excelente para manejo de datos
Haystack 2.x	Muy robusto para pipelines empresariales

Documento preparado por: Equipo de Desarrollo **Fecha:** Enero 2026 **Versión:** 1.1